

PREGUNTA 1

El "Representation learning" es una técnica de aprendizaje automático que se enfoca en aprender a representar los datos de una manera que sea útil para resolver tareas específicas, como clasificación o regresión. En lugar de simplemente aprender a predecir etiquetas o valores específicos, el objetivo es aprender una representación de los datos que capture las características importantes y distintivas de los mismos. Esto puede mejorar el rendimiento en tareas posteriores y hacer que el modelo sea más eficiente y preciso.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT press. Capítulo 14.

PREGUNTA 2

El "stochastic gradient learning" es una técnica de aprendizaje automático que permite entrenar modelos de manera más rápida y eficiente en grandes conjuntos de datos. En lugar de utilizar todo el conjunto de datos para actualizar los parámetros del modelo en cada iteración, esta técnica utiliza un subconjunto aleatorio de los datos. Esto hace que el proceso de entrenamiento sea más rápido y escalable, y puede ayudar a evitar el sobreajuste.

Bottou, L. (2010). Large-scale machine learning with stochastic gradient descent. In Proceedings of COMPSTAT'2010. Springer.

PREGUNTA 3

La función ReLU (Rectified Linear Unit) es una función de activación utilizada en redes neuronales artificiales. Esta función toma un valor de entrada y devuelve el mismo valor si es positivo, y cero si es negativo. En otras palabras, la función ReLU "apaga" cualquier valor negativo y mantiene los valores positivos.

La utilidad de la función ReLU es que puede ayudar a resolver el problema de la desaparición del gradiente en redes neuronales profundas. La desaparición del gradiente ocurre cuando los gradientes se vuelven muy pequeños a medida que se propagan hacia atrás en la red, lo que puede hacer que el proceso de entrenamiento sea muy lento o incluso imposible. La función ReLU puede ayudar a evitar este problema al mantener los gradientes en una escala más manejable.

Además, la función ReLU es computacionalmente eficiente y fácil de implementar, lo que la hace una opción popular en muchas aplicaciones de aprendizaje profundo.

Nair, V., & Hinton, G. E. (2010). Rectified linear units improve restricted boltzmann machines. In Proceedings of the 27th international conference on machine learning (ICML-10) (pp. 807-814).

PREGUNTA 4

En la práctica, los mínimos locales no suelen ser un problema importante en el entrenamiento de grandes redes neuronales. Aunque es posible que una red neuronal se quede atrapada en un local y no pueda encontrar el mínimo global óptimo, en la mayoría de los casos, los algoritmos de optimización utilizados en el entrenamiento de redes neuronales son lo suficientemente robustos como para escapar de los mínimos locales y encontrar soluciones cercanas al mínimo global. Además, existen técnicas de regularización que pueden ayudar a evitar que la red neuronal se quede atrapada en mínimos locales.

En resumen, aunque los mínimos locales pueden ser un problema teórico en el entrenamiento de grandes redes neuronales, en la práctica no suelen ser un problema importante debido a la robustez de los algoritmos de optimización utilizados y a las técnicas de regularización disponibles.

Choromanska, A., Henaff, M., Mathieu, M., Arous, G. B., & LeCun, Y. (2015). The loss surfaces of multilayer networks. In *Artificial Intelligence and Statistics* (pp. 192-204). PMLR.

PREGUNTA 5

Las Convolutional Neural Networks (CNNs) son un tipo de red neuronal que se utiliza para procesar imágenes y videos. Las CNNs utilizan capas convolucionales para extraer características de las imágenes y capas de pooling para reducir la dimensionalidad de las características extraídas. Luego, las capas completamente conectadas utilizan las características extraídas para realizar tareas de clasificación o detección de objetos.

Las CNNs son muy útiles en aplicaciones de visión por computadora, como la clasificación de imágenes y la detección de objetos. También se utilizan en otras aplicaciones, como la segmentación de imágenes y la generación de imágenes.

*Las capas convolucionales son un tipo de capa utilizada en las Convolutional Neural Networks (CNNs) para procesar datos de imágenes y videos. Estas capas aplican filtros a la imagen de entrada para detectar características locales, como bordes, texturas y formas.

LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436-444.

PREGUNTA 6

Las Autoencoders Neural Networks (AEs) son un tipo de red neuronal que se utiliza para aprender una representación comprimida de los datos de entrada. La red neuronal consta de dos partes: un codificador que transforma los datos de entrada en una representación comprimida, y un decodificador que reconstruye los datos de entrada a partir de la representación comprimida.

El propósito de las AEs es reducir la dimensionalidad de los datos de entrada y extraer características relevantes de los mismos. Esto puede ser útil en aplicaciones como la reducción de ruido en imágenes, la compresión de datos y la generación de datos sintéticos.

Por ejemplo, los AEs se han utilizado para la clasificación de imágenes médicas, como las tomografías computarizadas (CT) y las resonancias magnéticas (MRI). Los AEs pueden aprender patrones complejos en estas imágenes y luego utilizar esta información para clasificarlas en diferentes categorías, como imágenes normales o imágenes con anomalías.

Además, los AEs también se han utilizado para la identificación de patrones en secuencias de ADN. Los AEs pueden aprender patrones en secuencias de ADN y luego utilizar esta información para identificar regiones importantes en el genoma, como regiones promotoras o regiones codificantes.

Por último, los AEs también se han utilizado para la predicción de la estructura de proteínas. Los AEs pueden aprender patrones en secuencias de aminoácidos y luego utilizar esta información para predecir la estructura tridimensional de la proteína.

Bengio, Y., Courville, A., & Vincent, P. (2013). Representation learning: A review and new perspectives. *IEEE transactions on pattern analysis and machine intelligence*, 35(8), 1798-1828.

PREGUNTA 7

Las Recurrent Neural Networks (RNNs) son un tipo de red neuronal que se utiliza para procesar datos secuenciales, como texto, audio y video. A diferencia de las redes neuronales tradicionales, que procesan los datos de manera secuencial, las RNNs utilizan conexiones recurrentes que les permiten mantener una memoria interna y procesar secuencias de longitud variable.

El propósito de las RNNs es modelar la dependencia temporal en los datos de entrada y producir una salida que depende de toda la secuencia de entrada. Las RNNs son especialmente útiles en aplicaciones de procesamiento de lenguaje natural, como la traducción automática y la generación de texto.

Por ejemplo, las RNNs se han utilizado para la predicción de la estructura de proteínas. Las RNNs pueden modelar la relación entre los aminoácidos en una

secuencia de proteínas y utilizar esta información para predecir la estructura tridimensional de la proteína.

Además, las RNNs también se han utilizado para la clasificación de secuencias de ADN. Las RNNs pueden modelar la relación entre los nucleótidos en una secuencia de ADN y utilizar esta información para clasificar la secuencia en diferentes categorías, como secuencias codificantes o secuencias no codificantes.

Por último, las RNNs también se han utilizado para la predicción de la actividad de fármacos. Las RNNs pueden modelar la relación entre la estructura química de un fármaco y su actividad biológica y utilizar esta información para predecir la actividad de fármacos en diferentes contextos biológicos.

Lipton, Z. C., Berkowitz, J., & Elkan, C. (2015). A critical review of recurrent neural networks for sequence learning.

PREGUNTA 8

Las MANN se utilizan para mejorar la capacidad de las RNN para procesar datos secuenciales mediante la adición de una unidad de memoria externa. Las MANN tienen la capacidad de actualizar y acceder a la memoria externa, lo que les permite realizar tareas más complejas que las RNN convencionales. En este artículo se proponen dos extensiones a las MANN que agregan varias capacidades presentes en otras MANN, y se evalúa el rendimiento de las MANN aplicadas directamente a la traducción automática.

En resumen, las MANN son una clase de redes neuronales recurrentes que se utilizan para el procesamiento de datos secuenciales y tienen una unidad de memoria externa que les permite realizar tareas más complejas que las RNN convencionales.

Collier, M., & Beel, J. (2019). Memory-Augmented Neural Networks for Machine Translation.

PREGUNTA 9

Los algoritmos generativos, como las Generative Adversarial Networks (GAN) y los Variational AutoEncoders (VAE), son un tipo de modelo de aprendizaje automático que se utiliza para generar datos nuevos a partir de un conjunto de datos de entrenamiento. Estos modelos aprenden a generar datos nuevos que son similares a los datos de entrenamiento, pero no idénticos.

Las GANs son un tipo de modelo generativo que consta de dos redes neuronales: un generador y un discriminador. El generador produce datos nuevos a partir de un ruido aleatorio, mientras que el discriminador evalúa si los datos generados son reales o falsos. Durante el entrenamiento, el generador

aprende a producir datos que engañen al discriminador, mientras que el discriminador aprende a distinguir entre los datos reales y los generados.

Los VAEs son un tipo de modelo generativo que consta de un codificador y un decodificador. El codificador transforma los datos de entrada en una representación comprimida, mientras que el decodificador reconstruye los datos de entrada a partir de la representación comprimida. Durante el entrenamiento, el modelo aprende a generar datos nuevos a partir de la distribución latente de la representación comprimida.

Los algoritmos generativos tienen aplicaciones en la generación de imágenes, la síntesis de voz y la generación de texto, entre otras. Estos modelos pueden ser útiles en situaciones en las que se necesitan datos nuevos para entrenar otros modelos o para realizar pruebas.

Kingma, D. P., & Welling, M. (2013). Auto-encoding variational bayes.

Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. (2014). Generative adversarial nets. In Advances in neural information processing systems (pp. 2672-2680).

Pregunta 10

Los Transformers son un tipo de modelo de aprendizaje automático utilizado en el procesamiento del lenguaje natural (NLP). Los Transformers se basan en una arquitectura de red neuronal que utiliza atención para procesar secuencias de entrada.

La atención es un mecanismo que permite a la red neuronal enfocarse en partes específicas de la secuencia de entrada durante el procesamiento. Los Transformers utilizan múltiples capas de atención para procesar la secuencia de entrada y producir una salida.

El propósito de los Transformers es mejorar el rendimiento en tareas de NLP, como la traducción automática, la generación de texto y la respuesta a preguntas. Los Transformers han demostrado ser muy efectivos en estas tareas y han superado a los modelos anteriores en términos de precisión y velocidad.

Las aplicaciones de los Transformers son numerosas y van desde la traducción automática y la generación de texto hasta la respuesta a preguntas y la detección de sentimientos. Algunos ejemplos de aplicaciones incluyen la traducción automática de idiomas, la generación de subtítulos para videos y la respuesta a preguntas basadas en un contexto.

Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention is all you need. Advances in neural information processing systems, 30, 5998-6008.

Pregunta 11

Big Data es un término que se refiere a conjuntos de datos extremadamente grandes y complejos que no pueden ser procesados por herramientas de procesamiento de datos tradicionales. Estos conjuntos de datos pueden incluir información de diversas fuentes, como redes sociales, sensores, transacciones financieras y registros médicos.

El propósito del Big Data es extraer información valiosa y conocimientos útiles a partir de estos conjuntos de datos. Esto puede ser útil en una variedad de aplicaciones, como la toma de decisiones empresariales, la investigación científica y la detección de fraudes.

Las herramientas utilizadas para procesar y analizar Big Data incluyen tecnologías de almacenamiento y procesamiento distribuido, como Hadoop y Spark, y técnicas de análisis de datos, como el aprendizaje automático y la minería de datos.

Las aplicaciones del Big Data son numerosas y van desde la detección de fraudes y la optimización de la cadena de suministro hasta la investigación científica y la atención médica personalizada.

Manyika, J., Chui, M., Brown, B., et al. (2011). Big data: The next frontier for innovation, competition, and productivity. McKinsey Global Institute, 1-156.

PREGUNTA 12

Los métodos bioinspirados son un conjunto de técnicas de inteligencia artificial que se basan en la observación y el estudio de la naturaleza para resolver problemas complejos. Estos métodos se inspiran en los procesos biológicos y en los comportamientos de los organismos vivos para desarrollar algoritmos y modelos de aprendizaje automático.

Algunos ejemplos de métodos bioinspirados incluyen las redes neuronales artificiales, que se inspiran en el cerebro humano, y los algoritmos genéticos, que se basan en la evolución biológica.

El propósito de los métodos bioinspirados es desarrollar soluciones innovadoras y eficientes para problemas complejos que no pueden ser resueltos con métodos tradicionales. Estos métodos pueden ser útiles en una variedad de aplicaciones, como la optimización de procesos industriales, la detección de fraudes y la toma de decisiones empresariales.

Las aplicaciones de los métodos bioinspirados son numerosas y van desde la robótica y la visión por computadora hasta la medicina y la biología. Algunos ejemplos de aplicaciones incluyen el diseño de robots autónomos, la detección de enfermedades a partir de imágenes médicas y la optimización de procesos de producción.

Yang, X. S. (2010). Nature-inspired metaheuristic algorithms. Luniver press

PREGUNTA 13

Aprendizaje por refuerzo en biología: El aprendizaje por refuerzo es una técnica de aprendizaje automático que se basa en el concepto de recompensa y castigo para mejorar el rendimiento de un modelo. En biología, el aprendizaje por refuerzo se utiliza para modelar el comportamiento de los organismos y para desarrollar estrategias de control de plagas.

Sutton, R. S., & Barto, A. G. (2018). Reinforcement learning: An introduction. MIT press.

Redes neuronales convolucionales en análisis de imágenes médicas: Las redes neuronales convolucionales son un tipo de red neuronal que se utiliza para procesar imágenes y reconocer patrones en ellas. En biología, las redes neuronales convolucionales se utilizan en el análisis de imágenes médicas para la detección de enfermedades y la identificación de patrones de expresión génica.

Litjens, G., Kooi, T., Bejnordi, B. E., et al. (2017). A survey on deep learning in medical image analysis. Medical image analysis, 42, 60-88.

Modelos de redes bayesianas en biología de sistemas: Las redes bayesianas son un tipo de modelo probabilístico que se utiliza para modelar la incertidumbre en los datos y las relaciones entre las variables. En biología de sistemas, las redes bayesianas se utilizan para modelar las interacciones entre los componentes de un sistema biológico y para predecir su comportamiento.

Friedman, N., & Koller, D. (2003). Being Bayesian about network structure. A Bayesian approach to structure discovery in Bayesian networks, 23-50.

Algoritmos genéticos en diseño de fármacos: Los algoritmos genéticos son un tipo de algoritmo de optimización que se basa en la evolución biológica. En el diseño de fármacos, los algoritmos genéticos se utilizan para optimizar la estructura de las moléculas y para predecir su actividad biológica.

Goodarzi, M., & Soltani, S. (2019). A review on applications of genetic algorithms in drug design. Journal of molecular graphics and modelling, 88, 195-209.